

Este análisis lo vamos a utilizar con dos fines:

- Reducir la dimensionalidad de los datos


Se pretende pasar de p variables a k comp. principales que son comb. lineales de todas las variables.

- Estudiar la relación entre las variables.
- Aplicar un método que NO requiere que NO haya correlación entre sus variables (p.e: Regresión Lineal)

Interpretación geométrica

Cada comp. va a definir una dirección $a_i = (a_{i1}, \dots, a_{ip})$. Se quiere encontrar aquellas direcciones que expliquen la mayor variabilidad posible de los datos.

Ej: 2 variables



La 1ª comp. principal max. la varianza de las proy. de las variables.

La 2ª comp. principal será ortogonal a la 1ª comp. y max. la varianza restante.

Observaciones:

- 1) Si hay p variables, se necesitan p CP para capturar el 100% de la variabilidad.
- 2) En general, se puede capturar gran parte de la variabilidad con $k \ll p$.
- 3) El dataset se queda como $n \times k$

Un poco de teoría

Consideremos el vector aleatorio

$$X = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix} \text{ con matriz de cov. } \Sigma$$

Queremos construir las comp. principales:

$$Y_1 = a_1' X = a_{11}X_1 + \dots + a_{1p}X_p \quad (1 \text{ CP})$$

\vdots

$$Y_p = a_p' X = a_{p1}X_1 + \dots + a_{pp}X_p \quad (p \text{ CP})$$

Tenemos que:

$$\text{Var}(Y_i) = a_i' \Sigma a_i$$

$$i = 1, \dots, p$$

$$\text{Cov}(Y_i, Y_k) = a_i' \Sigma a_k = 0 \quad i \neq k$$

↳ Las CP son comb. lineales de X NO correlacionadas entre sí.

Por tanto, buscamos las a_i 's tal que:

- La 1a comp. principal es $a_1' X$ tal que $a_1 \max \text{Var}(a_i' X)$
- La 2a " " " $a_2' X$ " " $a_2 \max \text{Var}(a_i' X)$,

la $\text{cov}(a_1' X, a_2' X) = 0$ y a_2 es ortogonal a a_1 .

\vdots

- La i -ésima comp. principal es $a_i' X$ tal que $a_i \max \text{Var}(a_i' X)$,
la $\text{cov}(a_i' X, a_k' X) = 0$ y a_i es ortogonal a las anteriores.

¿Qué valen a_i 's?

Teorema: Sea Σ la matriz de cov. de $X = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$. Suponga que Σ tiene pares de valores y vectores propios:

$$(\lambda_1, e_1), (\lambda_2, e_2), \dots, (\lambda_p, e_p) \quad \text{con} \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

La i -ésima comp. principal se define como:

$$Y_i = e_i' X \quad (\text{es decir, } a_i = e_i \text{ vector propio})$$

"scores"

Además:

$$\text{Var}(Y_i) = e_i' \Sigma e_i = \lambda_i \quad i = 1, \dots, p$$

$$\text{Cov}(Y_i, Y_k) = 0 \quad i \neq k$$

Observaciones:

1) La varianza total se preserva.

2) La prop. de varianza explicada por la k -ésima CP es:

$$\frac{\lambda_k}{\lambda_1 + \dots + \lambda_p}$$

3) En muchas ocasiones para las 1as comp. principales esta proporción es 0.8-0.9

4) Si el vector principal i es $e_i = \begin{pmatrix} e_{i1} \\ \vdots \\ e_{ip} \end{pmatrix}$, entonces $|e_{ik}|$ mide la "importancia" de la variable k en la i -ésima CP.

Más aún, $e_{ik} \sim \rho_{Y_i, X_k}$ (corr. entre CP i y variable k)

Concretamente:

$$\rho_{Y_i, X_k} = \frac{e_{ik} \sqrt{\lambda_i}}{\sqrt{\sigma_{X_k}}} \quad i, k = 1, \dots, p$$

"Loadings"


Nota: Si los datos están estandarizados utilizamos P en vez de Σ

Número apropiado de comp. principales

i) Mirado la prop. de varianza explicada acumulada y decidir cuanta info. es suficiente (80-85%)

ii) Regla del codo (Elbow)

100%+



Cogeríamos 2 CP.

Ejemplo numérico.

Example 8.1 (Calculating the population principal components)

Suppose the random variables X_1 , X_2 and X_3 have the covariance matrix

$$\Sigma = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

It may be verified that the eigenvalue-eigenvector pairs are

$$\left. \begin{array}{l} \lambda_1 = 5.83, \quad \mathbf{e}'_1 = [.383, -.924, 0] \\ \lambda_2 = 2.00, \quad \mathbf{e}'_2 = [0, 0, 1] \\ \lambda_3 = 0.17, \quad \mathbf{e}'_3 = [.924, .383, 0] \end{array} \right\} \text{dirección CP}$$

Therefore, the principal components become

$$Y_1 = \mathbf{e}'_1 \mathbf{X} = .383X_1 - .924X_2$$

$$Y_2 = \mathbf{e}'_2 \mathbf{X} = X_3$$

$$Y_3 = \mathbf{e}'_3 \mathbf{X} = .924X_1 + .383X_2$$

The variable X_3 is one of the principal components, because it is uncorrelated with the other two variables.

Equation (8-5) can be demonstrated from first principles. For example,

$$\left. \begin{array}{l} \text{Var}(Y_1) = \text{Var}(.383X_1 - .924X_2) \\ \quad = (.383)^2 \text{Var}(X_1) + (-.924)^2 \text{Var}(X_2) \\ \quad \quad + 2(.383)(-.924) \text{Cov}(X_1, X_2) \\ \quad = .147(1) + .854(5) - .708(-2) \\ \quad = 5.83 = \lambda_1 \\ \text{Cov}(Y_1, Y_2) = \text{Cov}(.383X_1 - .924X_2, X_3) \\ \quad = .383 \text{Cov}(X_1, X_3) - .924 \text{Cov}(X_2, X_3) \\ \quad = .383(0) - .924(0) = 0 \end{array} \right\} \text{Comprobación}$$

It is also readily apparent that

$$\sigma_{11} + \sigma_{22} + \sigma_{33} = 1 + 5 + 2 = \lambda_1 + \lambda_2 + \lambda_3 = 5.83 + 2.00 + .17$$

validating Equation (8-6) for this example. The proportion of total variance accounted for by the first principal component is $\lambda_1/(\lambda_1 + \lambda_2 + \lambda_3) = 5.83/8 = .73$. Further, the first two components account for a proportion $(5.83 + 2)/8 = .98$ of the population variance. In this case, the components Y_1 and Y_2 could replace the original three variables with little loss of information.

Next, using (8-8), we obtain

$$\begin{aligned} \rho_{Y_1, X_1} &= \frac{e_{11}\sqrt{\lambda_1}}{\sqrt{\sigma_{11}}} = \frac{.383\sqrt{5.83}}{\sqrt{1}} = .925 \\ \rho_{Y_1, X_2} &= \frac{e_{21}\sqrt{\lambda_1}}{\sqrt{\sigma_{22}}} = \frac{-.924\sqrt{5.83}}{\sqrt{5}} = -.998 \end{aligned}$$

Notice here that the variable X_2 , with coefficient $-.924$, receives the greatest weight in the component Y_1 . It also has the largest correlation (in absolute value) with Y_1 . The correlation of X_1 , with Y_1 , .925, is almost as large as that for X_2 , indicating that the variables are about equally important to the first principal component. The relative sizes of the coefficients of X_1 and X_2 suggest, however, that X_2 contributes more to the determination of Y_1 than does X_1 . Since, in this case, both coefficients are reasonably large and they have opposite signs, we would argue that both variables aid in the interpretation of Y_1 .

Finally,

$$\rho_{Y_2, X_1} = \rho_{Y_2, X_2} = 0 \quad \text{and} \quad \rho_{Y_2, X_3} = \frac{\sqrt{\lambda_2}}{\sqrt{\sigma_{33}}} = \frac{\sqrt{2}}{\sqrt{2}} = 1 \quad (\text{as it should})$$

The remaining correlations can be neglected, since the third component is unimportant. ■

Ejemplo gráfico (R)